Servicio Nacional de Aprendizaje
SENA
Proceso de Gestión de Formación Profesional Integral

Solución de la Guía de Aprendizaje No. 1

Resumen de temas del trimestre I

Autor: Alejandro José Arrieta Cotera
Ficha: 3533558
Docente: Ing. Nathalia Martínez Vargas

Procesamiento de Datos para Modelos de Inteligencia Artificial
Trimestre II
Centro de Materiales y Ensayos

Fecha de entrega: 31 de octubre de 2026, 11:59 p. m.
Fecha de Solución 27 de octubre de 2026

Bogota.DC

Índice

1. Presentación

2. Actividades

2.1. Actividades de reflexión inicial 2

2.2. Actividades de contextualización e identificación de conocimientos..... 3

2.3. Actividades de apropiación 3

2.4. Actividades de transferencia del conocimiento 3

Resumen de temas del trimestre I

1. Presentación

2. Actividades

2.1. Actividades de reflexión inicial

1. Si un error tan “básico” como no revisar las unidades de medida destruyó un proyecto de 125
millones de dólares en la NASA, ¿qué consecuencias podría tener para una empresa actual
procesar un archivo de Excel sin saber si la columna “¿Ventas” está en
pesos colombianos, dólares o euros?

R//: Un error aparentemente pequeño como equivocarse en la columna de ventas y no calcular bien los datos de monetización puede implicar bastantes perdidas en la empresa, también se llega a perder la confianza en los empleados, por eso es importante validar la información antes de procesarla y así no convertirse en una perdida millonaria para la empresa

2.Teniendo en cuenta el caso de la sonda espacial, ¿por qué cree que la ficha de caracterización
de variables (diccionario de datos) es el paso más importante antes de empezar a escribir código en Python o SQL?

R//: considero que es importante tener en cuenta la ficha de caracterización de variables al momento de escribir datos en Python o SQL, precisamente para no cometer el error que se presenta en el texto de la sonda espacial, esto dado que por un error de comunicación y diferencias en los diferentes datos y estadísticas se ocasionó ese incidente, lo que en SQL o en Python conllevaría a un error en las líneas de código

3.Si mañana llega a su primer trabajo y el gerente le entrega un archivo (.csv, .xlsx o .json) lleno de números sin ninguna explicación (sin metadatos), ¿cuál debería ser su primera acción como analista de datos antes de aplicar cálculos o transformaciones?

R//: si una empresa me llegara a entregar un archivo, no importa el formato de importación, lo primero es verificar si en el archivo hay datos nulos, datos duplicados

o cualquier tipo de dato que pueda afectar el proceso, y así preguntar de que trata y que quiere exactamente que le entregue con lo que me entregaron.

4.Hoy en día existe una obsesión por tener “Big Data” (millones de registros). A partir del caso
de estudio, ¿de qué sirve tener millones de datos y las mejores herramientas si se comete un fallo en la etapa de comprensión estructural del dato?

R//: no basta con tener muchos datos ni las mejores herramientas; es fundamental comprender, organizar y validar la información antes de procesarla

2.2 Actividades de contextualización e identificación de conocimientos

Fase 1 del Proyecto Integrador.

Usted deberá buscar y seleccionar de forma autónoma un conjunto de datos (dataset) de su interés en los portales de Datos Abiertos Bogotá, OpenML o Kaggle. Una vez seleccionado, analizara el contexto de la información y deberá plantear al menos tres (3) preguntas de negocio que puedan ser respondidas con esos datos.

R//: Seleccione una Dataset de uno de los portales abiertos de Kaggle llamada Bank-additional, y las tres preguntas que formula son las siguientes.

¿Qué ocupaciones tienen porcentaje de clientes que encontraron el depósito?

¿Porque medio de contacto y que mes se lograron más aceptaciones?

¿En qué trimestre del año hay mayor tasa de aceptaciones?

2.3 Actividades de apropiación

Fase 2 del Proyecto Integrador: Usando el dataset elegido en la actividad anterior, desarrolle:

- Estructurar la ficha de caracterización (diccionario de variables) detallando cada columna

- Utilizando Google Colab, importara el archivo plano (.csv o .xlsx) y aplicara librerías y funciones de Python que conozca para realizar la limpieza de los datos: identificación y Resumen de temas del trimestre I 5 tratamiento de nulos, eliminación de duplicados, ajuste de tipos de datos, y los que considere necesarios.
- Generar un Análisis Exploratorio de Datos (EDA), incluya gráficos que considere necesarios para entender cómo se relacionan las variables entre sí.

VARIABLE	DESCRIPCIÓN	CATEGORÍA	TIPO DE DATO	RANGO / VALORES	OBSERVACIONES / SIGNIFICADO
AGE	Edad del cliente	Demográfica	Numérica (Entero)	18 - 88 años	Representa la edad física de la persona contactada.
JOB_TITLE	Ocupación o tipo de trabajo del cliente	Demográfica	Categórica Nominal	admin., blue-collar, technician, services, management, retired, entrepreneur, self-employed, housemaid, unemployed, student, unknown	Indica el sector laboral del cliente. Contiene valores 'unknown' para registros incompletos.
MARITAL	Estado civil del cliente	Demográfica	Categórica Nominal	married, single, divorced, unknown	'divorced' agrupa a personas divorciadas y viudas.
EDUCATION	Nivel educativo alcanzado por el cliente	Demográfica	Categórica Ordinal	basic.4y, basic.6y, basic.9y, high.school, illiterate, professional.course, university.degree, unknown	Nivel máximo de estudios cursados por el cliente.
CREDIT_IN_ DEFAULT	Historial de créditos en mora o impagos	Financiera/Historial	Categórica Nominal/Binaria	no, yes, unknown	Indica si el cliente ha incumplido alguna obligación

					crediticia en el pasado.
HOUSING	Préstamo hipotecario vigente	Financiera/Historial	Categórica Nominal/Binaria	no, yes, unknown	Indica si el cliente tiene un préstamo activo para vivienda.
LOAN	Préstamo personal vigente	Financiera/Historial	Categórica Nominal/Binaria	no, yes, unknown	Indica si el cliente posee un préstamo personal de consumo activo.
CONTACT	Medio de comunicación utilizado para contactar al cliente	Campaña Actual	Categórica Nominal	cellular (móvil), telephone (fijo)	Vía por la cual se realizó el último contacto.
LAST_CONTACT_MONTH_OF_YEAR	Último mes en el que se contactó al cliente en el año	Campaña Actual	Categórica Nominal	jan, feb, mar, ..., nov, dec	Mes del último contacto en la campaña actual.
DAY_OF_WEEK	Día de la semana del último contacto	Campaña Actual	Categórica Nominal	mon, tue, wed, thu, fri	Día hábil en el que se efectuó la última llamada telefónica.
DURATION	Duración de la última llamada en segundos	Campaña Actual	Numérica Continua	0 - 3643 segundos	Nota crítica: Si duration = 0, entonces y = 'no'. Es una variable de alto impacto predictivo.
CAMPAIGN	Número de contactos acumulados durante esta campaña para este cliente	Campaña Actual	Numérica Discreta	1 - 35 contactos	Incluye la llamada actual efectuada al cliente.
PDAYS	Días transcurridos desde el último	Campañas Previas	Numérica Discreta	0 - 999 días	El valor especial '999' significa que el cliente

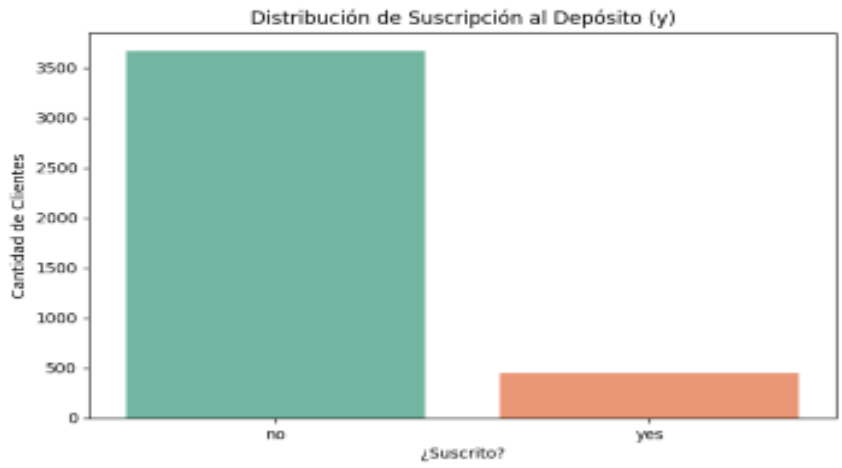
	contacto en una campaña previa				nunca antes fue contactado.
PREVIOUS	Cantidad de contactos previos realizados a este cliente	Campañas Previas	Numérica Discreta	0 - 6 contactos	Número de interacciones comerciales antes del inicio de esta campaña.
POUTCOME	Resultado de la campaña de marketing anterior	Campañas Previas	Categórica Nominal	failure, nonexistent, sucres	Muestra si la relación previa con el cliente terminó con éxito o fracaso.
EMP.VAR.RATE	Tasa de variación del empleo (indicador trimestral)	Socioeconómica	Numérica Continua	-3.4 a 1.4	Mide los cambios de empleo en la economía de la Eurozona.
CONS.PRICE.IDX	Índice de precios al consumo (mensual)	Socioeconómica	Numérica Continua	92.201 - 94.767	Indicador macroeconómico sobre el costo de vida y la inflación.
CONS.CONF.IDX	Índice de confianza del consumidor (mensual)	Socioeconómica	Numérica Continua	-50.8 a -26.9	Indica el nivel de optimismo o pesimismo de los consumidores locales.
EURIBOR3M	Tasa de referencia interbancaria Euribor a 3 meses	Socioeconómica	Numérica Continua	0.635 - 5.045	Tipo de interés diario ofrecido para préstamos entre bancos.
NR.EMPLOYED	Número de personas empleadas en el país (trimestral)	Socioeconómica	Numérica Continua	4963.6 - 5228.1 (en miles de personas)	Volumen general de empleo nacional registrado en el período.
DEPOSIT_SUSCRIBED	Suscripción al producto de	Variable Objetivo (Target)	Categórica Nominal/Binaria	yes, no	Indica el éxito comercial de la llamada actual.

	depósito a plazo fijo				Variable para predecir.

1. Distribución de la Variable Objetivo (`y`)

Este gráfico permite analizar qué tan balanceadas o desbalanceadas están las clases en el conjunto de datos (suscripción exitosa vs. no exitosa).

```
plt.figure(figsize=(8, 5))
sns.countplot(x='y', data=df, palette='Set2', hue='y', legend=False)
plt.title('Distribución de Suscripción al Depósito (y)')
plt.xlabel('¿Suscrito?')
plt.ylabel('Cantidad de Clientes')
plt.show()
```

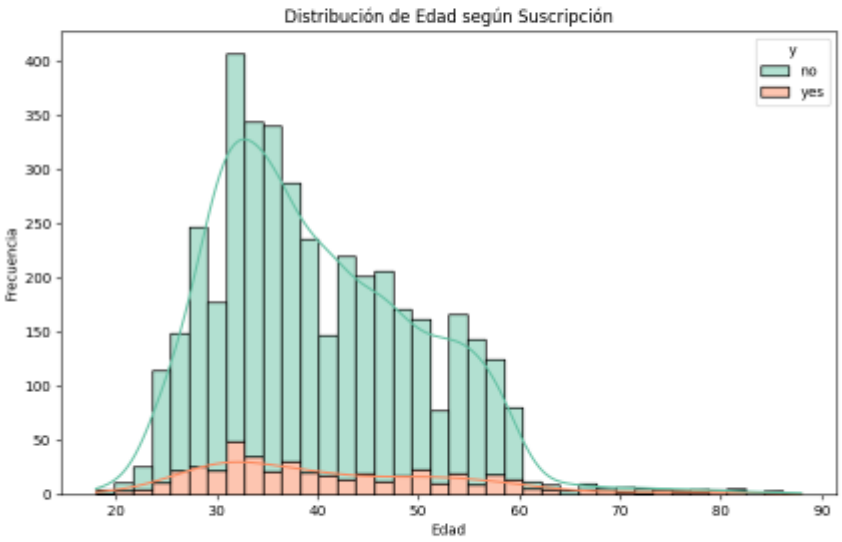


El Bloque Económico (Relación Muy Fuerte) euribor3m (tasas de interés) - nr.employed (empleados) - emp.var.rate (tasa de empleo): Tienen una correlación casi perfecta (entre 0.91 y 0.97). Esto significa que cuando la economía está fuerte (sube el empleo), las tasas de interés también suben de inmediato. Aportan casi la misma información.

2. Distribución de la Edad según la Suscripción

Este análisis ayuda a comprender a qué edades es más probable que los clientes se suscriban al depósito.

```
plt.figure(figsize=(10, 6))
sns.histplot(data=df, x='age', hue='y', multiple='stack', palette='Set2', kde=True)
plt.title('Distribución de Edad según Suscripción')
plt.xlabel('Edad')
plt.ylabel('Frecuencia')
plt.show()
```

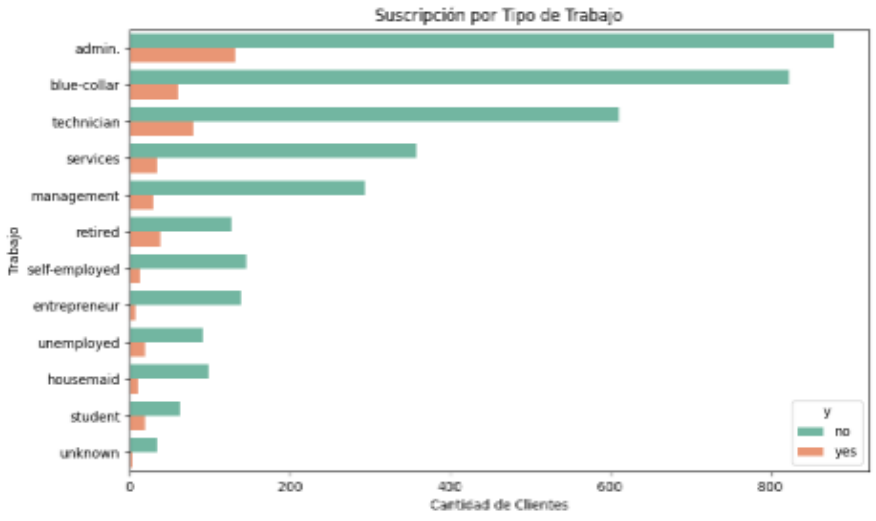


Campañas de Contacto (Relación Moderada) pdays (días desde el último contacto) y previous (contactos anteriores): Tienen una relación inversa (-0.58). Cuanto más contacto se ha tenido con un cliente en el pasado, menos tiempo ha transcurrido desde la última vez que se le llamó. euribor3m (tasas de interés) y previous (contactos anteriores): Tienen una relación negativa (-0.58). En épocas con tasas de interés más bajas, se realizaron más campañas y contactos previos.

3. Suscripción por Tipo de Trabajo (`job`)

Este gráfico permite identificar cuáles sectores u ocupaciones tienen mayor volumen de contactos y una mejor tasa de conversión.

```
plt.figure(figsize=(10, 6))
sns.countplot(y='job', hue='y', data=df, palette='Set2', order=df['job'].value_counts().index)
plt.title('Suscripción por Tipo de Trabajo')
plt.xlabel('Cantidad de Clientes')
plt.ylabel('Trabajo')
plt.show()
```

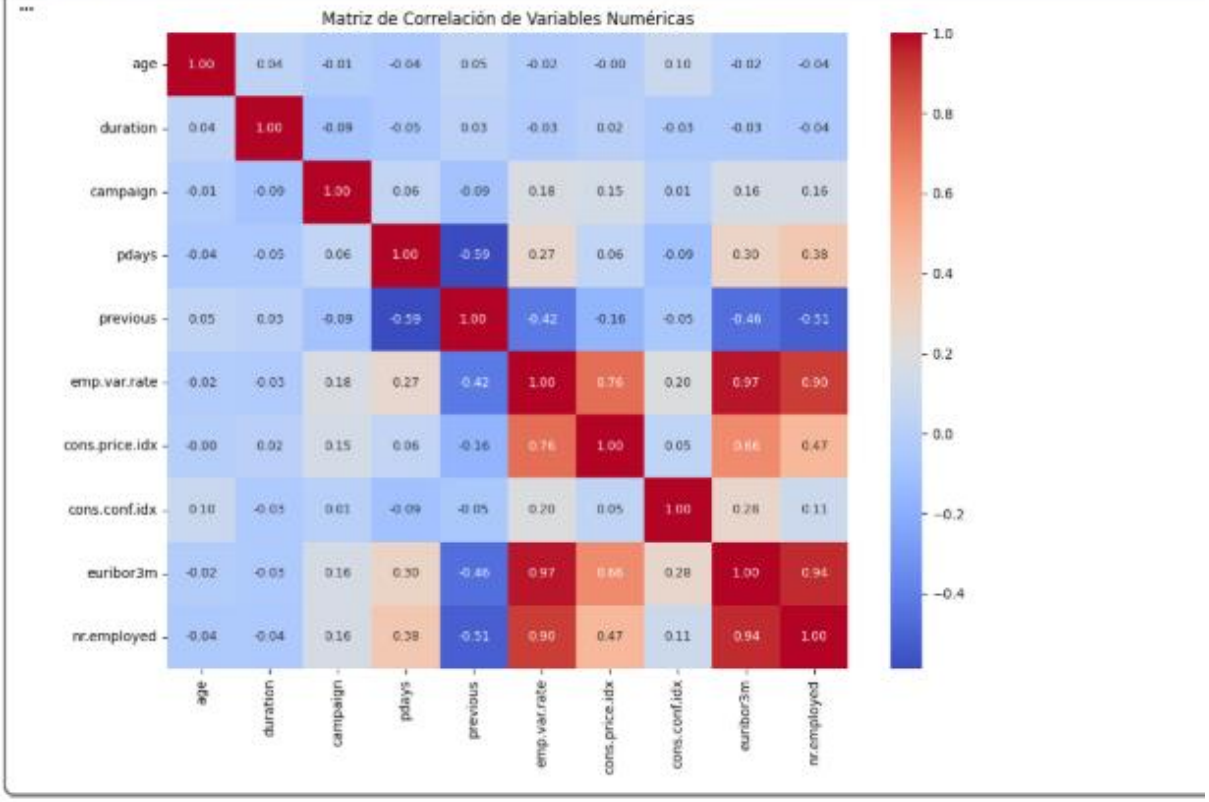


Edad y Comportamiento (Sin Relación Directa) La edad (age) no tiene apenas relación matemática directa con el resto de variables numéricas. Su comportamiento (como la preferencia de jóvenes y jubilados) se ve de forma visual en los gráficos de distribución, no de forma lineal.

4. Matriz de Correlación de Variables Numéricas

Este mapa de calor muestra el grado de relación lineal entre las variables numéricas y los indicadores macroeconómicos.

```
plt.figure(figsize=(10, 8))
numeric_cols = ['age', 'duration', 'campaign', 'pdays', 'previous', 'emp.var.rate', 'cons.price.idx', 'cons.conf.idx', 'euribor3m', 'nr.employed']
corr_matrix = df[numeric_cols].corr()
sns.heatmap(corr_matrix, annot=True, fmt='.2f', cmap='coolwarm', cbar=True, annot_kws={'size': 9})
plt.title('Matriz de Correlación de Variables Numéricas')
plt.tight_layout()
plt.show()
```



Edad y Comportamiento (Sin Relación Directa) La edad (age) no tiene apenas relación matemática directa con el resto de variables numéricas. Su comportamiento (como la preferencia de jóvenes y jubilados) se ve de forma visual en los gráficos de distribución, no de forma lineal.

2.4 Actividades de transferencia el conocimiento

Fase 3 del Proyecto Integrador

Con el dataset completamente limpio e importado en un entorno de base de datos relacional (como SQLite Online o integrado en Colab), responda a las 3 preguntas de negocio formuladas en la fase de contextualización. Para ello, diseñará y ejecutará consultas en SQL (usando SELECT, WHERE, GROUP BY, JOIN, etc.). Finalmente, consolide todo el proyecto en un reporte único donde presentara las consultas realizadas y las conclusiones estratégicas que obtuvo a partir de los datos.

R//: Primera pregunta

```
2          `job_title` AS ocupacion,
3          COUNT(*) AS total_clientes,
4          SUM(CASE WHEN `deposit_subscribed` = 'yes' THEN 1 ELSE 0 END) AS aceptaron,
5          ROUND(SUM(CASE WHEN `deposit_subscribed` = 'yes' THEN 1 ELSE 0 END) * 100.0 / COUNT(*), 2) AS porcentaje_aceptacion
6      FROM bank_additional.bank_loans
7      GROUP BY `job_title`
8      ORDER BY porcentaje_aceptacion DESC;
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

ocupacion	total_clientes	aceptaron	porcentaje_aceptacion
student	82	19	23.17
retired	166	38	22.89
unemployed	111	19	17.12
admin.	1012	133	13.14
technician	691	80	11.58
unknown	39	4	10.26
housemaid	110	11	10.00
management	324	30	9.26
services	393	35	8.91
self-employed	159	13	8.18
blue-collar	884	61	6.90
entrepreneur	148	8	5.41

R//: Segunda pregunta

```
2          `contact`                    AS medio_contacto,
3          `last_contact_month_of_year` AS mes,
4          COUNT(*)                     AS aceptaciones
5      FROM bank_additional.bank_loans
6      WHERE `deposit_subscribed` = 'yes'
7      GROUP BY `contact`, `last_contact_month_of_year`
8      ORDER BY aceptaciones DESC;
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

medio_contacto	mes	aceptaciones
cellular	may	62
cellular	aug	61
cellular	jul	56
cellular	jun	44
cellular	nov	39
cellular	apr	32
telephone	may	28
cellular	mar	26
telephone	jun	24
cellular	sep	23
cellular	oct	21
cellular	dec	11
telephone	nov	4
telephone	oct	4
telephone	apr	4
telephone	jul	3
telephone	aug	3

Result 2

Output

Action Output

#	Time	Action	Message
1	19:46:11	SELECT `contact` AS medio_contacto, `last_contact_month_of_year` AS mes, COUNT(*) AS aceptaciones FROM ...	20 row(s) returned

R//: tercera pregunta

```sql
SELECT
    CASE
        WHEN `last_contact_month_of_year` IN ('jan','feb','mar') THEN 'Q1 (Ene-Mar)'
        WHEN `last_contact_month_of_year` IN ('apr','may','jun') THEN 'Q2 (Abr-Jun)'
        WHEN `last_contact_month_of_year` IN ('jul','aug','sep') THEN 'Q3 (Jul-Sep)'
        WHEN `last_contact_month_of_year` IN ('oct','nov','dec') THEN 'Q4 (Oct-Dic)'
    END                                                          AS trimestre,
    COUNT(*)                                                     AS total_contactos,
    SUM(CASE WHEN `deposit_subscribed` = 'yes' THEN 1 ELSE 0 END)    AS aceptaciones,
    ROUND(SUM(CASE WHEN `deposit_subscribed` = 'yes' THEN 1 ELSE 0 END) * 100.0 / COUNT(*), 2) AS tasa_aceptacion
FROM bank_additional.bank_loans
GROUP BY trimestre
ORDER BY tasa aceptacion DESC;
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

trimestre	total_contactos	aceptaciones	tasa_aceptacion
Q1 (Ene-Mar)	48	28	58.33
Q4 (Oct-Dic)	537	80	14.90
Q3 (Jul-Sep)	1411	149	10.56
Q2 (Abr-Jun)	2123	194	9.14

Result 2

Output

Action Output

#	Time	Action				Message
1	19:48:13	SELECT	CASE	WHEN 'last_contact_month_of_year` IN ('jan','feb','mar') THEN 'Q1 (Ene-Mar)'	WHEN 'last_contact_month_of_year` IN ('apr'...	4 row(s) returned

Refencias

https://www.kaggle.com/

CHAT.GPT: use esta IA, para que me ayudara con la pregunta de la sonda espacial, se usó un 15%

GEMMINI: use esta IA, para comprender y que me explicara la creación de las gráficas (ED), se usó un 25%

CLAUD.IA: use esta IA, en la formulación de las preguntas en SQL,

se usó el 3%